

A interatividade da plataforma **Amazon AquaBio** utiliza o poder das *engines* JavaScript mais recentes (como o V8 do Google Chrome ou SpiderMonkey do Firefox), transferindo a carga computacional do servidor para o cliente (o navegador do usuário).

Isso é viabilizado pelo paradigma das **Single Page Applications (SPA)**. Ao carregar a aplicação, o navegador recebe um modelo estrutural e o código da lógica de negócios (JavaScript). Os dados são carregados com base na consulta direta ao JSON assim que a página é aberta, resultando na redução de custos operacionais, como o processamento ocorre na CPU do usuário, o custo computacional para o provedor do serviço é zero, garantindo que o projeto possa permanecer online indefinidamente sem orçamento de nuvem.


3.5.5 Conclusão da Fundamentação: Sustentabilidade como Requisito Não-Funcional

Em engenharia de software, requisitos não-funcionais (como manutenibilidade e sustentabilidade) são tratados como tão importantes quanto as funcionalidades do sistema. A combinação de orquestração de workflows reproduzíveis (Nextflow/Docker) com uma camada de apresentação desacoplada e estática, propõe que o esforço computacional investido na montagem dos genomas da ictiofauna amazônica não se degrade com o passar do tempo, ou seja, servidores desligados ou discos rígidos inacessíveis, mas permaneça como um ativo digital perene, interoperável e globalmente acessível, cumprindo a promessa de democratizar o conhecimento genômico.

4 MATERIAIS E MÉTODOS

Para proporcionar uma compreensão clara da metodologia e etapas envolvidas neste estudo foi desenvolvido um fluxograma (**Figura 7**). Ilustrando não apenas o fluxo de trabalho desenvolvido mas também todos os *softwares* utilizados em cada etapa do processo, além dos arquivos intermediários de entrada e de saída de cada processo. A organização visual do diagrama permite uma compreensão clara da sequência de operações, das ferramentas envolvidas e dos *outputs* esperados em cada estágio da análise de mitogenomas.


Figura 7 – Fluxograma ilustrando as etapas, ferramentas e produtos do fluxo de trabalho de análise de mitogenomas, com formas e cores padronizadas para distinguir processos, decisões, ferramentas e arquivos. Os círculos em rosa marcam o início e o fim do fluxo de trabalho, delimitando o escopo da análise. Os retângulos em cinza representam as ferramentas bioinformáticas utilizadas. Os losangos em azul indicam os arquivos intermediários, sendo eles os produtos gerados em cada etapa.



Fonte: Elaborado pelo autor, 2026.

4.1 Seleção de Amostra

Figura 8 – Fluxograma ilustrando as etapas, ferramentas e produtos do fluxo de trabalho de análise de mitogenomas, com formas e cores padronizadas para distinguir processos, decisões, ferramentas e arquivos - Em Destaque: Fluxo da Etapa de Seleção dos Dados.



Fonte: Elaborado pelo autor, 2026.

A escolha dos dados, portanto das espécies de peixes amazônicos para compor este trabalho foram obtidas do repositórios do National Center for Biotechnology Information

(NCBI), através de scripts para realizar consultas cruzadas entre os bancos de dados de taxonomia, nucleotídeos e sequence read archive (SRA), a partir dos seguintes critérios:

1. **Plataforma:** Apenas dados de sequenciamento de genoma total (whole Genome Sequencing – WGS) gerados em plataformas Illumina foram selecionados.
2. **Biblioteca:** Amostras que utilizaram exclusivamente Bibliotecas Paired-End(pe)
3. **Representatividade:** Priorização de espécies com baixa representatividade mitocondrial no GenBank (menos de 3 mitogenomas completos depositados) e alta relevância econômica ou evolutiva (DAGOSTA; DE PINNA, 2019).
4. **Redundância:** Seleção de espécies que possuíssem, preferencialmente, no mínimo três conjuntos de dados brutos (SRA) provenientes de diferentes indivíduos e/ou bioprojetos distintos, visando validar a reprodutibilidade do *pipeline* em diferentes condições de sequenciamento.

Com algumas exceções: a espécie *Pygocentrus nattereri* (Kner, 1858) teve amostras diferentes derivadas do mesmo indivíduo e duas espécies de ciclídeos possuíam apenas 2 SRA. Os dados foram acessados entre novembro de 2023 e maio de 2024. Totalizando 100 mitogenomas pertencentes a 34 espécies de peixes amazônicos. Sendo 30 espécies da família Cichlidae, 2 espécies da família Serrasalminidae e 2 espécies da família Osteoglossidae.

Os dados da família Cichlidae foram obtidos do projeto (PRJEB48774) conduzido pelo Instituto Sanger, cujo objetivo é sequenciar amostras de 288 ciclídeos brasileiros, com uma cobertura de 17X, utilizando o sequenciador Illumina NovaSeq 150bp PE. Os dados das famílias Serrasalminidae e Osteoglossidae que foram adicionadas a esse estudo também foram obtidos por bibliotecas de WGS disponíveis no NCBI (**TS1 – Tabela Suplementar 1**).

A triagem das amostras não foi realizada manualmente. Foi desenvolvido uma rotina de busca utilizando as **NCBI E-utilities** (API Entrez) (O'LEARY et al., 2024) para cruzar metadados de diferentes bancos. O fluxo lógico da mineração seguiu as seguintes etapas:

1. **Consulta Taxonômica:** Inicialmente, scripts em *Bash* e *Python* foram utilizados para varrer a árvore taxonômica de famílias de interesse (ex: Cichlidae, Serrasalminidae) e recuperar os *Taxonomy IDs* (TaxIDs) de espécies amazônicas.
2. **Verificação de Lacunas:** Para cada TaxID, o script consultou o banco *NCBI Nucleotide* para verificar a existência de mitogenomas completos ("*mitochondrion*" AND "*complete genome*"). Espécies com amplas lacunas de informação foram marcadas como prioritárias.

Para automatizar o processo e permitir a montagem em larga escala, desenvolveu-se o pipeline **Mitomine** (disponível publicamente em: <https://github.com/gleisonm/mitomine>) feito em colaboração com outros pesquisadores. Diferente da execução manual de scripts, o Mitomine foi construído sobre o gerenciador de fluxo de trabalho Nextflow (DI TOMMASO et al., 2017). Essa abordagem nos permitiu criar um workflow onde o processamento das amostras ocorreu de forma paralela e modular, utilizando contêineres (Docker/Singularity) para garantir que cada ferramenta operasse em um ambiente virtual isolado entre si.

A primeira etapa da montagem, tem como input um arquivo em formato CSV (*Comma-Separated Values*) contendo especificamente o código de acesso único (Accession ID) do *Sequence Read Archive* (SRA) para cada amostra escolhida na etapa de seleção de amostra, o pipeline lê arquivo e instância processos paralelos de download utilizando o pacote **SRA Toolkit v3.0**. A ferramenta **prefetch** é executada para transferir os arquivos **.sra** compactados, gerenciando dinamicamente a fila de download com base na largura de banda de rede e no espaço em disco disponível, após baixar os dados brutos, os arquivos binários do SRA são separados para o formato de sequência bruta FASTQ. Utiliza-se a ferramenta **fastq-dump** com o parâmetro **--split-files**. Este parâmetro é utilizado para dados *Paired-End* (Illumina), pois realiza a separação das leituras *Forward* (R1) e *Reverse* (R2) em arquivos distintos, preservando a informação de emparelhamento e distância de inserção (*insert size*). Com as leituras brutas, inicia-se a montagem *de novo* de organelas. Para esta etapa, optou-se pelo algoritmo **NOVOPlasty v4.3** (DIERCKXSENS et al., 2017). O NOVOPlasty funciona com base na *Seed-and-Extend* ("Semente e Extensão"), requerindo uma "isca" para iniciar o recrutamento de leituras. Neste estudo, padronizou-se o uso do mitogenoma completo da espécie *Pygocentrus nattereri* (GenBank: NC_015840.1) como semente universal. A escolha desta espécie (Piranha-vermelha) justifica-se pela conservação evolutiva de genes codificadores de proteínas (como *cox1* e *cytb*) e RNAs ribossomais entre *P. nattereri* e a ictiofauna amazônica alvo garante que haja identidade de sequência suficiente para o "ancoramento" inicial das leituras, mesmo em espécies distantes.

Otimização via Hash Table (Aceleração de 23%): Para o algoritmo *Seed-and-Extend* é necessário varrer o arquivo FASTQ inteiro repetidamente. Para mitigar esse problema, o pipeline Mitomine implementa a funcionalidade de indexação por *Hash* do NOVOPlasty. Na primeira execução, o montador constrói uma Tabela Hash (*Hash Table*) mapeando todas as leituras da biblioteca. Em vez de descartar esse índice ao final, o pipeline persiste em disco. Caso a montagem falhe ou precise ser refinada com novos parâmetros (ex:

ajuste de *k-mer*), o NOVOPlasty reutiliza este arquivo de Hash como *input* direto, ignorando a leitura dos arquivos FASTQ originais. Para quantificar o ganho, mediu-se o tempo de parada de montagem em 100 amostras, cada uma executada com e sem reaproveitamento do índice, na mesma máquina (48 CPUs, 236 RAM, Debian 12 SO) e sem outras cargas concorrentes. A reutilização do índice reduziu o tempo total de execução por amostra em média 53%.

4.2.1 Fluxo de Validação Cruzada (Fluxo Superior)

Como forma de validar os mitogenomas montados pelo NOVOPlasty (nosso montador principal), foi-se utilizada um segundo montador o Unicycler como forma de validação cruzada, conforme ilustrado na parte destacada da **Figura 9**.

1. **Mapeamento (BWA-MEM):** As leituras originais (R1 e R2) são alinhadas contra o contig do NOVOPlasty utilizando o algoritmo *Burrows-Wheeler Aligner* (LI, 2013). O objetivo é capturar todas as leituras que pertencem à mitocôndria, descartando contaminação nuclear.
2. **Conversão e Extração:** Os arquivos de alinhamento (.SAM) são processados via SAMtools e convertidos novamente em sequências brutas (.FASTQ) utilizando o utilitário **bamToFastq** da suíte **Bedtools v2.30**.
3. **Remontagem Híbrida (Unicycler):** Estes novos Fastqs limpos alimentam o montador **Unicycler** (WICK et al., 2017). O Unicycler utiliza uma lógica matemática distinta (Grafos de De Bruijn otimizados) para montar as sequências.

A validação cruzada das montagens foi realizada através do alinhamento par-a-par entre os contigs gerados pelo NOVOPlasty e pelo Unicycler. Altos valores de identidade entre as duas sequências confere alto grau de confiança ao resultado final (**TS2 – Tabela Suplementar 2**). Nos casos em que houve discrepâncias, observou-se que o Unicycler frequentemente solucionou regiões repetitivas que impediram a circularização na mitocôndria no NOVOPlasty. Todos os mitogenomas também foram comparados com o banco de dados NCBI-NR utilizando uma análise BLAST v. 2.16 (<https://blast.ncbi.nlm.nih.gov/Blast.cgi>) (MCGINNIS; MADDEN, 2004) (**TS3 – Tabela Suplementar 3**).

4.2.2 Detecção de Heteroplasmia e Variantes (Fluxo Inferior)

O "Fluxo Inferior" da metodologia foca na diversidade individual de cada organela. A heteroplasmia trata-se da coexistência de múltiplas variantes do genoma mitocondrial dentro da mesma célula ou tecido.

Para detectar esse fenômeno, utiliza-se o módulo *Heteroplasmy Caller* integrado ao NOVOPlasty. A lógica computacional difere da montagem de consenso da seguinte forma:

1. O algoritmo alinha todas as leituras de volta contra o mitogenoma montado e circularizado.
2. Para cada posição nucleotídica, ele calcula a frequência de cada base (A, C, T, G).
3. **Exemplo Prático:** Se na posição 1.450 a base de referência é Adenina (A), mas 970 leituras mostram A e 30 leituras mostram Guanina (G), o sistema avalia se essa variante "G" é um erro de sequenciamento ou uma heteroplasmia real com base no valor de MAF.

Parâmetros de Filtragem Estatística: Para distinguir ruído de heteroplasmia real, aplicam-se as seguintes métricas (DUAN; TU; LU, 2018):


- **MAF (*Minor Allele Frequency*):** A variante deve aparecer em uma frequência mínima (tipicamente >1.5% ou >3% dependendo da profundidade).
- **Cobertura Mínima (*Depth*):** Variantes de baixa frequência (<3%) só são reportadas se a posição tiver uma cobertura de sequenciamento superior a 300x (*Deep Sequencing*).
- **Score de Qualidade (*Phred*):** Bases com qualidade de sequenciamento (Q-score) inferior a 20 (precisão <99%) são excluídas do cálculo antes da chamada da variante.

O resultado dessa chamada de heteroplasmia gera arquivos intermediários contendo as posições polimórficas, que servem de input para a geração de gráficos de diversidade nucleotídica nas etapas de visualização do projeto.

4.3 Anotação funcional

Após a etapa de validação da circularidade e integridade estrutural das montagens, os mitogenomas foram submetidos à etapa de anotação funcional (Como mostrado na figura 10) para identificação dos 37 genes (13 codificadores de proteínas - PCGs, 22 RNAs transportadores - tRNAs e 2 RNAs ribossomais - rRNAs) e da região controle (D-loop).

Figura 10 – Fluxograma ilustrando as etapas, ferramentas e produtos do fluxo de trabalho de análise de mitogenomas, com formas e cores padronizadas para distinguir processos, decisões, ferramentas e arquivos - Em Destaque: Fluxo da Etapa de Anotação das Mitocôndrias.



Fonte: Elaborado pelo autor, 2026.

A anotação dos 100 mitogenomas foi feita de forma automatizada primeiramente pela ferramenta **MitoAnnotator**, que é integrada ao banco de dados MitoFish v.4.03 (ZHU et al., 2023). Esta ferramenta foi selecionada especificamente por ser especializada em anotação de peixes, utilizando um extenso banco de dados composto por dados próprios e dados do ncbi, fornecendo uma alta precisão taxonômica.

O MitoAnnotator executa, inicialmente, a reorientação da sequência circular. O algoritmo localiza o gene **tRNA-Phe** (tRNA de Fenilalanina) e rotaciona a sequência para que este gene ocupe a primeira posição, padronizando o início do genoma logo após a região controle (D-loop), conforme a convenção para vertebrados, essa ação se faz importante para que exista uma padronização no momento de gerar as imagens para análise dos dados, principalmente no caso das análises de sintenia.

Heurísticas de Predição de Genes (PCGs):

A determinação das fronteiras dos genes codificadores de proteínas (Start e Stop codons) segue um algoritmo hierárquico similar a uma árvore de decisão, buscando flexibilidade no processo de decisão das fronteiras:

Códon de parada (Stop Codon): O algoritmo estende as regiões de similaridade identificadas pelo BLASTX em busca de códons de parada canônicos. Em genes específicos conhecidos por sobreposição (ATP8, COX1, ND4L, ND5 e ND6), o sistema permite a sobreposição de leitura até o códon de parada do gene adjacente. Caso um *stop codon* completo não seja encontrado, o anotador trunca o gene na posição imediatamente anterior ao início do próximo elemento (posição -1), informando a presença de um "stop codon incompleto" (T-- ou TA-).

Códon de início (Start Codon): A busca pelo início da próxima região ocorre imediatamente após o término do gene anterior. O algoritmo tem como prioridade códons canônicos (ATG ou GTG) caso estejam ausentes, ele atribui flexibilidade com base na identidade do gene:

1. Para os genes *ND1*, *ND2*, *ND3*, *ND5*, *ATP6* e *ND4*, tolera-se uma sobreposição de até 1 par de base (bp).
2. Para os genes *ND1*, *ND3*, *ATP6* e *COX2*, tolera-se sobreposição de até 20 bp.

Persistindo a ambiguidade, o algoritmo busca por códons de iniciação alternativos específicos para certos genes (ex: CTG para *ATP6*, TTG para *ND1*, ATA/ATT para *ND3*). Em última instância, a decisão é tomada baseada na região mais comumente esperado para cada gene (ex: *ATP8* deve estar no intervalo de 170-220 pb; *ND5* entre 1600-1900 pb).

4.3.1 Validação Cruzada com MITOS2 e Comparação de Algoritmos

Embora o MitoAnnotator apresente alta acurácia para peixes, observou-se em algumas amostras a ocorrência de *start e stop codons* prematuros (*frameshifts*) ou anotações inconsistentes de PCGs. Para validar a anotação em busca de entender se a variação seria real ou apenas um erro de montagem ou de anotação, utilizou-se como segunda ferramenta o MITOS2 (BERNT et al., 2013; AL ARAB et al., 2017; DONATH et al., 2019), executado via servidor Galaxy.

A utilização de dois anotadores distintos justifica-se pelas diferenças entre as ferramentas que cada anotador utiliza para prever as posições dos genes. Enquanto o MitoAnnotator foca em similaridade de sequência direta (BLAST) contra um banco de peixes, o MITOS2 emprega modelos de covariância estrutural mais generalistas. A **Tabela 2** a seguir detalha as diferenças técnicas entre os motores de predição das duas ferramentas utilizadas, evidenciando as abordagens. Cabe ressaltar que ambas as ferramentas empregam o MiTFi para a predição de tRNAs. A validação cruzada é, portanto, independente apenas para PCGs e

rRNAs, cujos motores de predição diferem (BLASTX com regras de extensão versus HMM/Infernal); para os tRNAs, a concordância entre os dois anotadores reflete o uso do mesmo preditor e não constitui verificação independente.

Tabela 2 – Comparativo técnico dos algoritmos e motores de busca internos utilizados pelas ferramentas de anotação MitoAnnotator e MITOS2.


<i>Característica / Gene Alvo</i>	<i>MitoAnnotator (MitoFish)</i>	<i>MITOS2 (MITOS WebServer)</i>
<i>Foco Principal</i>	Especializado em Peixes (Banco de dados MitoFish). Baseado em anotação manual de 250 mitogenomas de peixes	Generalista para Metazoa (Animais). Baseado nos dados do RefSeq/NCBI.
<i>Predição de tRNAs</i>	Utiliza MiTFi (threshold e-value 1e-5). Escolhido pela sensibilidade superior ao tRNAscan-SE em mitocôndrias	Utiliza MiTFi. Ferramenta desenvolvida pelo próprio grupo para detectar estruturas secundárias conservadas.
<i>Predição de PCGs (Proteínas)</i>	BLASTX + Regras de Extensão. Busca similaridade no banco MitoFish e estende a região até encontrar Stop Codons vertebrados válidos (TAA, TAG, AGA, AGG)	HMMs + BLAST + Método Probabilístico. Usa HMMER para busca inicial e refina fronteiras maximizando a probabilidade conjunta de posição, frequência do códon e tamanho do gene.
<i>Predição de rRNAs (12S/16S)</i>	Modelo de Pontuação de tRNA (tRNA Punctuation Model). Assume que rRNAs preenchem o espaço entre tRNAs. Usa BlastN apenas se o gene predito for excessivamente longo.	Utiliza Infernal. Baseado em Modelos de Covariância (CMs) robustos para RNA estruturado, independentemente de tRNAs vizinhos.
<i>Tratamento de Sobreposição</i>	Regras Empíricas Rígidas. Permite sobreposições específicas de peixes: 1 bp para ND1, ND2, ND3, ND5; até 20 bp para ATP6 e ND4.	Probabilístico/Estatístico. Não usa regras fixas de "X pares de base", mas calcula a probabilidade estatística da fronteira baseada na conservação evolutiva e frequências de códons do clado.

Fonte: Elaborado pelo autor, 2026.

4.4 Análises bioinformáticas

A etapa de análise bioinformática foi pensando com oito eixos de análises, todas convergindo para o objetivo central de esclarecer a composição dos mitogenomas e identificar marcadores de proximidade taxonômica. Esta abordagem permitiu realizar análises em diferentes escalas: desde a variabilidade intra-individual, através da detecção de heteroplasmia, até a genômica comparativa (sintenia) e a inferência de distâncias evolutivas entre famílias. O fluxo das análises é apresentado na **Figura 11**.

Figura 11 – Fluxograma ilustrando as etapas, ferramentas e produtos do fluxo de trabalho de análise de mitogenomas, com formas e cores padronizadas para distinguir processos, decisões, ferramentas e arquivos - Em Destaque: Fluxo da Etapa de geração dos gráficos das Análises.



Fonte: Elaborado pelo autor, 2026.

Após a etapa de montagem e anotação, os arquivos FASTA processados foram submetidos a fluxos de trabalho específicos para caracterização estrutural e inferência evolutiva. Esta etapa pode ser dividida em dois módulos principais: reconstrução filogenética e análises de composição mitogenômica.

4.4.1 Reconstrução Filogenética

O fluxo de processos para a inferência filogenética foi desenhado para converter as sequências montadas em árvores binárias (formato Newick), seguindo uma sequência de alinhamento, modelagem e construção da árvore.

1. **Alinhamento Múltiplo de Sequências:** Os arquivos FASTA contendo os mitogenomas circularizados (mais especificamente o conjunto concatenado dos 13 Genes Codificadores de Proteínas - PCGs, de cada indivíduo) foram utilizados como *input* para o algoritmo **MAFFT v.7** (KATO et al., 2002), para alinhar as sequências homólogas e identificar regiões conservadas, gerando uma matriz de alinhamento.
2. **Seleção de Modelo Evolutivo:** A matriz de alinhamento foi processada pelo software **MEGA 11.0.13** (*Molecular Evolutionary Genetics Analysis*) (TAMURA; STECHER; KUMAR, 2021) para a determinação estatística do melhor modelo de substituição nucleotídica. O critério de seleção utilizado foi o **Critério de Informação de Akaike (AIC)**, que penaliza a complexidade do modelo para evitar o overfitting. Para o *dataset* analisado, o modelo General Time Reversible com distribuição Gama e Sítios Invariantes (**GTR + G + I**) foi retornado como o mais bem avaliado para explicar a variabilidade dos dados.
3. **Inferência da Árvore (Máxima Verossimilhança):** Com o alinhamento e o modelo evolutivo definidos, utilizou-se o **IQ-TREE v.2.3.6** (MINH et al., 2020) para a construção da árvore filogenética. O software foi executado utilizando o algoritmo estocástico de Máxima Verossimilhança (*Maximum Likelihood*). Para avaliar a robustez dos nós da árvore (suporte estatístico), aplicou-se o método de *Ultrafast Bootstrap* com 10.000 repetições. O *output* deste processo foi um arquivo de texto em formato Newick (**.nwk**), contendo a topologia da árvore e os comprimentos dos ramos.
4. **Renderização e Visualização:** A visualização final foi realizada através da ferramenta **iTOL v.6.9.1** (*Interactive Tree Of Life*) (LETUNIC; BORK, 2021). O arquivo **.nwk** gerado pelo IQ-TREE foi importado para a plataforma, permitindo a anotação gráfica dos clados, a renderização em formato circular ou retangular e a exportação de imagens vetoriais de alta resolução para publicação.

4.4.2 Análise de composição mitogenômica

Paralelamente à filogenia, desenvolveu-se uma suíte de *scripts* em **Python v.3.12.5** para automatizar a extração de métricas de composição dos arquivos montados e anotados, estes scripts iteram sobre o lote dos 100 genomas para gerar relatórios padronizados:

1. **Uso Relativo de Códon Sinônimos (RSCU):** A análise de viés de uso de códon foi implementada integrando o software **CaiCal** (PUIGBO *et al.*, 2008) ao fluxo Python. O *script* recebe como entrada o arquivo FASTA circularizado de cada indivíduo e executa o binário do CaiCal, que calcula as frequências absolutas e relativas. O *output* em formato tabular da ferramenta é capturado pelo *script*, tratado e convertido para arquivos no formato **.TSV**. Posteriormente, uma rotina de visualização lê estes dados tabulares e gera gráficos de barras para cada um dos 100 indivíduos, destacando a preferência de códon para cada aminoácido.
2. **Caracterização da Região Controle (D-loop):** A identificação de repetições em *tandem* na região controle utilizou a ferramenta **Tandem Repeats Finder (TRF)** v.4.10.0 (BENSON, 1999). Similar a análise de viés submete os genomas montados à ferramenta e recebe o arquivo de texto (.txt) gerado pelo TRF, contendo as coordenadas e sequências das repetições. O algoritmo extrai as métricas (tamanho da unidade de repetição e número de cópias) para compor a imagem final de análise da região D-loop.
3. **Análise de Sintenia:** Para a visualização da conservação ou do arranjo da ordem gênica, desenvolveu-se um script Python que utiliza como entrada os arquivos de anotação posicional em formato **.BED** (gerados na etapa de anotação). O script Python lê as coordenadas de início e fim de cada gene (PCGs, tRNAs e rRNAs) e plota diagramas lineares de sintenia, permitindo a análise visual da organização genômica das amostras.
4. **Visualização de Heteroplasmia:** A identificação de variantes intra-individuais foi realizada primariamente pelo módulo *Heteroplasmy Caller* do **NOVOPlasty**, configurado para detectar variações com Frequência de Alelo Menor (MAF) superior a 2%. Para a representação visual desses dados, os arquivos de variantes gerados pelo montador foram convertidos e utilizados como *input* na ferramenta **CIRCOS** (KRZYWINSKI *et al.*, 2009). Esta integração permitiu a geração de gráficos circulares que mapeiam a profundidade de cobertura (*depth of coverage*) e a localização dos sítios polimórficos ao longo do genoma mitocondrial.
5. **Assimetria Composicional (AT-skew e GC-skew):** A quantificação do viés de composição entre as fitas foi implementada em um script Python sem dependências externas, que recebe como entrada os arquivos FASTA de genes (*_genes.fa) produzidos pelo MitoAnnotator e, para as métricas de genoma inteiro, o próprio mitogenoma circularizado. Para cada uma das 38 features anotadas (13 PCGs, 22

tRNAs, 2 rRNAs e a região controle) o script contabiliza as bases e calcula $AT\text{-skew} = (A - T)/(A + T)$, $GC\text{-skew} = (G - C)/(G + C)$ e o conteúdo A+T% (PERNA; KOCHER, 1995), excluindo bases ambíguas tanto do numerador quanto do denominador e registrando o total excluído em coluna própria para auditoria. Como o skew é uma medida dependente de fita, reverso-complementar uma sequência inverte o sinal das duas métricas, e nove das 38 features de um mitogenoma de vertebrado situam-se na fita minoritária (ND6 e os tRNAs Gln, Ala, Asn, Cys, Tyr, Ser¹, Glu e Pro), o script calcula e grava lado a lado as duas convenções possíveis: todas as features medidas sobre a fita majoritária da montagem, adotada como padrão neste trabalho, por manter todas as regiões no mesmo referencial físico do genoma completo, condição para que a leitura da assimetria de replicação seja válida, e cada feature medida em sua própria fita codificadora, registrada em colunas de sufixo `_cod`, que preservam o significado biológico do índice em ND6 e nos oito tRNAs da fita minoritária. As duas saídas são numericamente idênticas para as 29 features da fita majoritária e diferem apenas pela inversão de sinal nas 9 features restantes, o que permite converter uma na outra sem recalculá-las. No final temos a dispersão $AT\text{-skew} \times GC\text{-skew}$, boxplots das cinco regiões canônicas (genoma completo, PCGs, tRNAs, rRNAs e região controle), e o diagrama de skew por feature, usado para localizar as inflexões associadas às origens de replicação (GRIGORIEV, 1998).

6. **Cobertura (coverage):** A verificação da sustentação das montagens pelas leituras que as originaram foram realizadas para cada indivíduo, utilizando uma sequência de operações do pacote SAMtools v.1.24 (DANECEK et al., 2021). O alinhamento das leituras contra o mitogenoma montado, previamente gerado, é ordenado por coordenada (`samtools sort`) e indexado (`samtools index`), possibilitando uma consulta posicional, em paralelo, o mitogenoma circularizado correspondente é recuperado e indexado como referência (`samtools faidx`), o que fixa o comprimento do contig e permite o acesso direto a qualquer posição da sequência. Com o alinhamento ordenado e a referência indexada, uma rotina de análise em Python, percorre o genoma e produz os arquivos de cobertura de cada indivíduo, dos quais resulta o gráfico de profundidade por posição: o eixo horizontal (X) representa a molécula linearizada, da primeira à última base, e o eixo vertical (Y) a profundidade de leituras naquela posição, com linhas horizontais de referência marcando os valores mínimo, médio e máximo observados na amostra. A leitura da figura distingue uma montagem uniformemente sustentada de outra em que trechos específicos, tipicamente as


extremidades da linearização e a região controle, rica em A+T e em repetições em tandem foram reconstruídos com profundidade muito inferior à do restante da molécula, indicando os pontos em que a sequência depositada deve ser interpretada com cautela.

7. **Sobreposições e Regiões Intergênicas:** Para caracterizar a compactação da molécula, desenvolveu-se um script Python que lê os arquivos de anotação dos genes, nos quais o cabeçalho de cada feature traz seu nome e suas coordenadas (>Gene início..fim(fita)), e calcula, para cada par de genes vizinhos, a diferença $\text{diff} = (\text{início do Gene B} - \text{fim do Gene A}) - 1$. O sinal do resultado classifica a junção: valores negativos indicam sobreposição de $|\text{diff}|$ bases, valor zero indica genes contíguos e valores positivos indicam um espaçador intergênico de diff bases. A natureza circular da molécula é preservada fechando o círculo entre a última e a primeira feature anotadas, de modo que todas as junções sejam avaliadas. No final uma imagem é plotada apresentando o mitogenoma ao longo do eixo X, e na conexão entre os genes é descrito a existência ou não de regiões intergênicas ou overlappings.

4.5 Geração de Primers

Os primers foram desenvolvidos com o Primer-BLAST (<https://www.ncbi.nlm.nih.gov/tools/primer-blast/>) (YE *et al.*, 2012), que utiliza o kit de ferramentas C++ do NCBI e a interface de programação Primer3, mesma parametrização adotada por Silva (2025). Os parâmetros para o tamanho do produto de PCR foram definidos com um mínimo de 70 bp e um máximo de 250 bp. A temperatura de fusão mais baixa (T_m) é 57,0°C, a temperatura de fusão mais alta é 63,0°C e a temperatura ideal é 60,0°C. Cada primer projetado foi atribuído a um organismo específico (**TS4 – Tabela Suplementar 4**). Para os primers da família, foram realizados alinhamentos utilizando o MAFFT v.7 (KATOHI *et al.*, 2002) e o EMBOSS Cons v.6.5.7 (https://www.ebi.ac.uk/jdispatcher/msa/emboss_cons) (RICE; LONGDEN; BLEASBY, 2000) para identificar sequências de consenso. O fluxo dos processos é representado em destaque na Figura 12, a seguir.

Figura 12 – Fluxograma ilustrando as etapas, ferramentas e produtos do fluxo de trabalho de análise de mitogenomas, com formas e cores padronizadas para distinguir processos, decisões, ferramentas e arquivos - Em Destaque: Fluxo da Etapa de Geração dos Primers.



Fonte: Elaborado pelo autor, 2026.

4.6 Engenharia da Plataforma Amazon AquaBio e Estratégia de Persistência

A consolidação e disponibilização dos dados gerados pelo *pipeline* e pelas análises posteriores culminou no desenvolvimento da plataforma **Amazon AquaBio** (acessível em: https://julio-csilva.github.io/Amazon_Aquabio/). A plataforma foi desenvolvida seguindo o paradigma de **Arquitetura Serverless Estática**, com foco em garantir a disponibilidade dos dados sem custos recorrentes de hospedagem e constante acesso.

4.6.1 Stack Tecnológico e Interface

O desenvolvimento do *front-end* não se limitou apenas a codificação, englobando também a concepção completa da identidade visual e a arquitetura de informação. O *design system* da plataforma foi criado totalmente "do zero", incluindo a definição de paleta de cores, tipografia e logotipos, visando criar uma identidade única que remetesse à biodiversidade amazônica sem comprometer a legibilidade dos dados científicos.

A navegação foi estruturada sob o paradigma de **Rolagem Infinita** (*Infinite Scroll*) guiada por **Narrativa Científica** (storytelling científico). Diferente de outros portais

segmentados em múltiplas abas, o *Amazon AquaBio* guia o usuário contando a jornada de descoberta: Apresentação do problema da escassez de dados na Amazônia, explicação didática sobre o que é o genoma mitocondrial e sua importância, estatísticas do projeto, mapeamento das espécies no território amazônico, resumo visual do fluxo de trabalho computacional e por fim acesso às amostras, imagens das espécies, referências bibliográficas e arquivos para *download*, essa estrutura foi desenhada intencionalmente para fomentar a pesquisa, garantindo que o usuário compreenda o contexto biológico antes de acessar as análises obtidas.

O front-end da aplicação foi construído como uma Single Page Application em React v18.2, compilada com Vite v6.3 e distribuída como conteúdo estático, escolha que mantém a compatibilidade em dispositivos com hardware limitado por transferir todo o custo de renderização para o navegador, sem servidor de aplicação.

- **Estrutura (HTML5):** Utilizou-se marcação semântica para garantir a acessibilidade e indexação por motores de busca, melhorando a visibilidade e leitura por ferramentas de automação (SEO).
- **Estilização e componentes:** a interface responsiva foi implementada com Grid Layout e Flexbox sobre a biblioteca de componentes Chakra UI v2.8, que padroniza barras de navegação, cartões de espécies e tipografia, permitindo a adaptabilidade do layout desde monitores desktop até dispositivos móveis.
- **Interatividade:** a manipulação da interface é feita pelo DOM Virtual do React, com roteamento por react-router-dom v6.23 em modo hash, condição necessária para a hospedagem estática.

4.6.2 Estrutura de Dados e Persistência (JSON)

Diferente da maioria das plataformas que consultam um banco de dados a cada requisição, o *Amazon AquaBio* utiliza uma arquitetura baseada em arquivos estáticos pré-processados. Os scripts de análise em Python (descritos na seção 4.4.2) geram as análises que são disponibilizadas junto da plataforma (RSCU, Skewness, Sintenia, Heteroplasma) e mapeadas no **JSON** (*JavaScript Object Notation*). O arquivo JSON atua como um "banco de dados estático". Cada espécie possui um identificador único que mapeia para seu arquivo de dados correspondente, garantindo que a recuperação da informação seja instantânea e cacheados por CDNs (*Content Delivery Networks*).

4.6.3 Lógica da Ferramenta Comparativa Client-Side

A interatividade da plataforma foi implementada seguindo o paradigma de *Single Page Application* (SPA), utilizando a biblioteca **React** para a construção de interfaces reativas baseadas em componentes. O *Amazon AquaBio* trabalha com **carregamento antecipado de dados** (*eager loading*).

O conjunto de dados processados, consolidado em arquivos JSON, é importado estaticamente nos componentes da aplicação. Durante o processo de *build* gerenciado pela ferramenta **Vite**, esses dados são serializados e incorporados diretamente ao *bundle* JavaScript. Essa abordagem elimina a latência de requisições HTTP assíncronas (como *fetch* ou *axios*) durante a navegação, garantindo que todo o *dataset* esteja disponível em memória imediatamente após o carregamento inicial da página. Um dos diferenciais da plataforma é a ferramenta de comparação interativa, que executa inteiramente no navegador do usuário (*client-side processing*). A lógica algorítmica foi implementada da seguinte forma: A seleção de espécies para comparação é controlada pelo sistema de estados do React (**useState**). A interface de seleção utiliza componentes da biblioteca **Chakra UI** para capturar eventos sintéticos (*Synthetic Events*) de interação do usuário (ex: **onChange**, **onClick**), atualizando dinamicamente vetores de IDs na memória do navegador sem recarregar a árvore DOM. A comunicação entre o módulo de seleção (**Comparador**) e o módulo de visualização (**Visualizador**) não utiliza armazenamento local (*Local Storage*) ou banco de dados, mas sim a manipulação de parâmetros de URL (*Query Strings*). Ao acionar o comando de geração de análise:

- O algoritmo serializa os IDs das espécies selecionadas.
- Utiliza-se a interface **URLSearchParams** para construir uma URL única contendo o estado da análise (ex: **?id1=especieX&id2=especieY**).
- Uma nova instância de visualização é aberta (**window.open**), garantindo que cada análise gerada possua um *link* compartilhável e reproduzível.

No componente de visualização, a aplicação lê os parâmetros passados pela URL e executa algoritmos de filtragem (*array filtering*) sobre o objeto JSON carregado em memória. A renderização dos dados comparativos (imagens, métricas e tabelas) ocorre instantaneamente através da atualização do DOM Virtual do React.

4.6.4 Gestão de Versão e Ciência Aberta

Para garantir a transparência, reprodutibilidade e longevidade do projeto, adotou-se uma estratégia de versionamento em multiplataforma:

Código-Fonte e Interface (GitHub): Todo o código do site, juntamente com os arquivos JSON de dados processados, está hospedado em um repositório público no **GitHub**. A implantação contínua (*Continuous Deployment*) é gerenciada pelo **GitHub Pages**, que reconstrói e publica o site automaticamente a cada atualização (*push*) no repositório.

Dados Brutos e Arquivos Intermediários (OSF): Devido às limitações de tamanho de repositórios de código, os arquivos de montagem brutos, alinhamentos BAM pesados e tabelas suplementares extensas foram depositados no **Open Science Framework (OSF)**. Links diretos na plataforma *Amazon AquaBio* conectam a visualização simplificada aos dados brutos no OSF, fechando o ciclo da Ciência Aberta.

A arquitetura do site foi desenvolvida visando a **reprodutibilidade para outros domínios**. O código-fonte foi estruturado de maneira desacoplada ao organismo; ou seja, a lógica de exibição (o *template* do site) é separada do conteúdo (os dados em JSON e imagens). Isso permite que outros grupos de pesquisa re-utilizem a estrutura do *Amazon AquaBio* para criar portais similares para outros táxons (como insetos, plantas ou mamíferos) apenas substituindo os arquivos de dados, sem necessidade de reescrever a lógica de programação do site.

5 RESULTADOS E DISCUSSÃO

5.1 Panorama dos Dados Públicos no NCBI-NR

A queda no custo do sequenciamento de alto rendimento fez os repositórios públicos crescerem em ordens de grandeza, e o NCBI concentra hoje um volume expressivo de submissões de origem brasileira, inclusive de natureza mitocondrial (NOREÑA-P et al., 2018). Esse volume, contudo, não se traduz em cobertura: aplicado ao acervo o filtro de mitogenomas completos, o número de registros recuperados cai de forma acentuada. A lacuna, portanto, não está nos dados brutos, está nos dados montados, anotados e depositados. Diante desse cenário, esse estudo contribui preenchendo essa lacuna através da